Programski prevodioci 1

Lekcija 2 – Leksička analiza

Uvod

Uloga leksičkog analizatora (skenera)

1. Isporučuje sintaksnom analizatoru terminalne simbole (tokene)

i	f		(	x	=	=	3	)		

→ skener → (IF,-) (LP,-) (ID, “x”) (EQ,-) (NUM,3) ...

niz znakova

niz tokena
(klasa, vrednost)

2. Ignoriše neke delove ulaznog teksta
   - razmake
   - tabulatore
   - znake za kraj linije (CR, LF)
   - komentare

Deterministički konačni automati

Konačni automati

Startno stanje označeno strelicom (ako je nema, onda stanje u prvoj vrsti tabele

Ulazni simboli

		0	1	
→	A	D	A	0
	B	A	C	0
	C	A	F	0
	D	B	C	0
	E	B	C	1
	F	E	A	1

A je stanje odbijanja

E je stanje prihvatanja

Stanja

δ- funkcija prelaza

$\delta(F, 1) = A$

- za određeno stanje i ulaz jednoznačno je određeno sledeće stanje => *deterministički* konačni automat (DKA)

Konačni automati

Deterministički konačni automat opisan je uređenom petorkom (S, U, δ, S_t, P) gde:

- S - skup stanja automata $S = \{A, B, C, D, E, F\}$;
- U - skup ulaznih simbola (azbuku automata), $U = \{0, 1\}$;
- $\delta: S \times U \rightarrow S$ predstavlja funkciju prelaza; za svako stanje i svaki ulazni simbol definiše novo stanje u koje automat prelazi iz stanja $s \in S$ za ulazni simbol $u \in U$; u ulaz tabele u vrsti X i koloni Y upisana je vrednost $\delta(X,Y)$;
- $S_t \in S$ je startno stanje automata $S_t = A$;
- $P \subseteq S$ skup stanja prihvatanja, $P = \{E, F\}$. Stanja iz skupa S-P su stanja odbijanja.

Graf prelaza konačnog automata

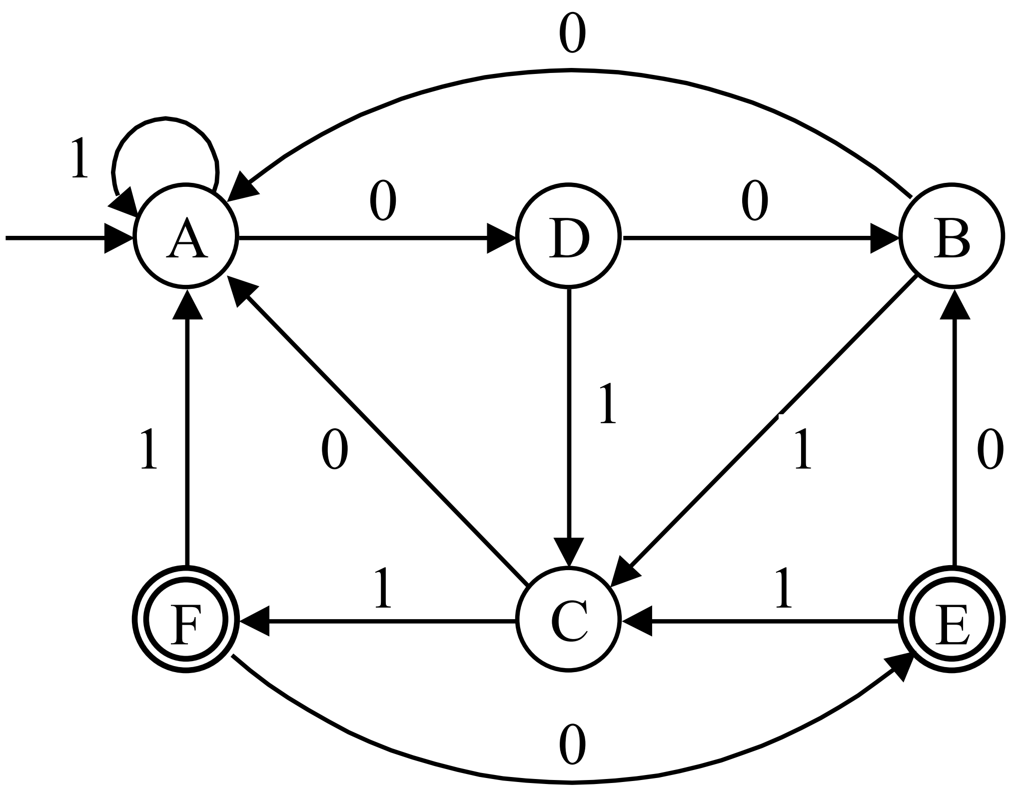

- Čvorovi: stanja
- Grane: prelazi

- Stanja prihvatanja: poduplano

Algoritam rada DKA

- Algoritam rada automata:

```
tekuće_stanje := St; { St – startno stanje}
tekući_ulaz := prvi simbol ulazne sekvence;
while not (kraj ulazne sekvence)
          tekuće_stanje := δ( tekuće_stanje, tekući ulaz );
                    tekući_ulaz := sledeći znak ulazne sekvence;
end while;
if ( tekuće_stanje ∈ P )      {P – skup stanja prihvatanja}
                    then ulazna sekvenca se prihvata;
                    else ulazna sekvenca se ne prihvata;
endif;
```

Jezik konačnog automata

- *Jezik* L(K) automata K = skup svih sekvenci ulaznih simbola koje automat prihvata.

Primer:

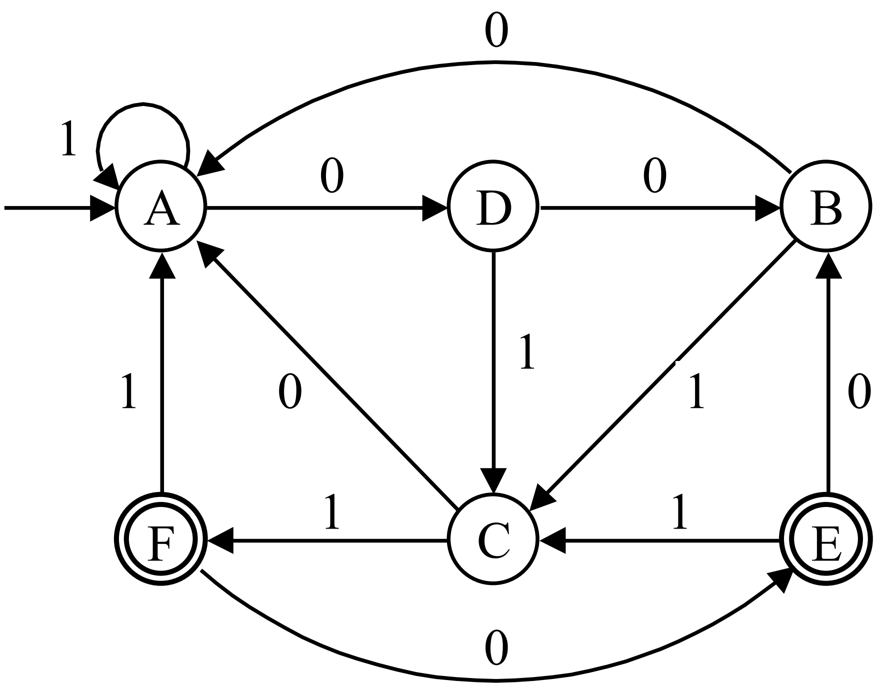

- rad automata za ulaz 0110

$$A \xrightarrow{0} D \xrightarrow{1} C \xrightarrow{1} F \xrightarrow{0} E$$

- završno stanje E je stanje prihvatanja ⇒ 0110 pripada jeziku L(K) automata K

- Probanjem:
  {1011, 0011, 011011, 011011011,...} $\in$ L(K)
  {0, 00, 00111, 1, 11, 111, 1111,...} $\notin$ L(K)

Skener u obliku DKA

Konceptualni primer: skener za tokene id, num, lp, gtr, geq

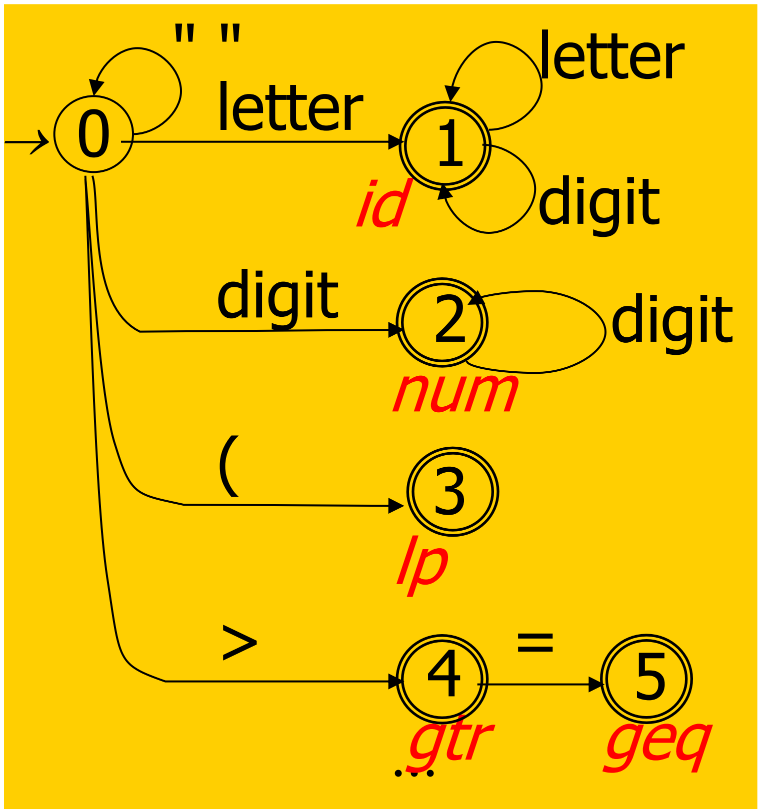

Ulazni niz: max >= 30

$s0 \xrightarrow{m\ a\ x} s1$

- Prepoznat *id*

$s0 \xrightarrow{>\ =} s5$

- Preskače beline na početku
- Prolazi kroz stanje 4
- Prepoznat *geq*

$s0 \xrightarrow{3\ 0} s2$

- Preskače beline na početku
- Prepoznat *num*

Posle svakog prepoznatog tokena skeniranje kreće ponovo od s0.

Nedeterministički konačni automati

Nedeterministički konačni automati

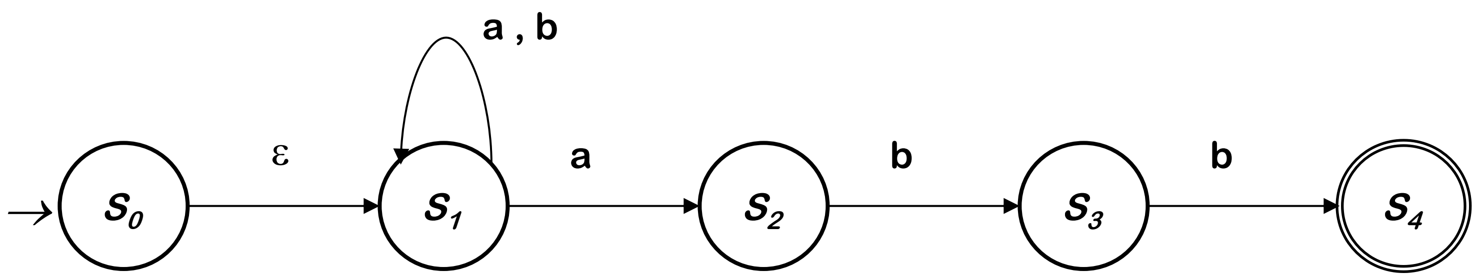

Specifičnosti automata:

- S_0 ima prelaz za ε (tzv. prazna sekvenca, automat može da pređe iz s0 u s1 a da pri tom ne konzumira nijedan simbol sa ulaza)
- S_1 ima dva različita prelaza za a

U pitanju je ***nedeterministički konačni automat*** **(NKA)**

Nedeterministički konačni automat

Opisan je uređenom petorkom (S, U, δ, S_t, P) gde:

- • S predstavlja skup stanja automata, za dati primer {s0, s1,s2,s3,s4,error}
- • U predstavlja skup ulaznih simbola (azbuku automata), $U = \{a, b\}$
- • $\delta: S \times (U \cup \{\varepsilon\}) \rightarrow P(S)$ predstavlja funkciju prelaza (P - partitivni skup); za svako stanje i svaki ulazni simbol definiše **skup** $S_N \subseteq S$ mogućih novih stanja u koje automat može preći iz stanja $s \in S$ za ulazni simbol $u \in U$ **ili za simbol prazne sekvence** ε
- • $S_t \subseteq S$ je **skup** startnih stanja automata. $S_t = \{s0\}$
- • $P \subseteq S$ predstavlja skup stanja prihvatanja, u konkretnom slučaju $P = \{s4\}$. Stanja iz skupa S-P nazivaju se stanjima odbijanja.

Rad datog NKA za ulaz abb

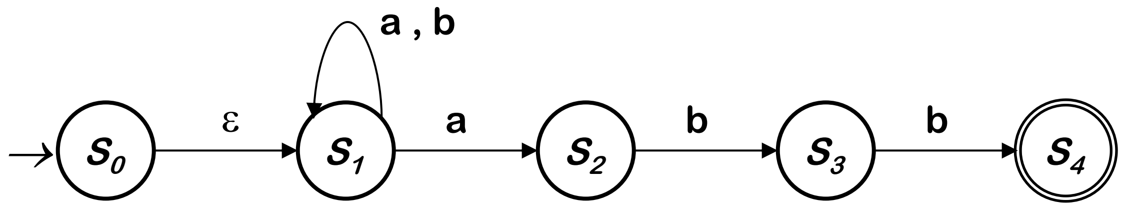

$s_0 \xrightarrow{\varepsilon} s_1 \xrightarrow{a} s_2 \xrightarrow{b} s_3 \xrightarrow{b} s_4$ ***prihvata?***

$s_0 \xrightarrow{\varepsilon} s_1 \xrightarrow{a} s_1 \xrightarrow{b} s_1 \xrightarrow{b} s_1$ ***odbija?***

$s_0 \xrightarrow{a} \mathit{error} \xrightarrow{b} \mathit{error} \xrightarrow{b} \mathit{error}$ ***odbija?***

itd

- **Generalno**, NKA prihvata ulaznu sekvencu *x* ako i samo ako za *x* postoji scenario promene stanja iz nekog od startnih stanja do nekog od stanja prihvatanja
- *U ovom primeru, NKA prihvata sekvencu abb*

Algoritam rada NKA

Za dati NKA i datu ulaznu sekvencu na izlazu daje podatak da li se sekvenca prihvata ili odbija.

Algoritam koristi funkciju ε-zatvaranja:

ε-closure(s) daje skup stanja dostižnih iz *s* po ε

Napomena: s je uključeno u skup

1. S″ = S′ = {s}
2. Za svako p iz S′
3. S″ = S″ $\cup$ δ(p, ε)
4. Ako je S″ = S′ onda kraj, rezultat je S″
5. S′ = S″;
6. Idi na korak 2

Algoritam rada NKA

- Moramo voditi evidenciju, u svakom koraku rada automata, o skupu svih mogućih stanja u kojima se automat može nalaziti.

```
tekući_skup_stanja := S_t;
tekući ulaz := prvi simbol ulazne sekvence;
while not (kraj ulazne sekvence)
    novi_skup_stanja := ∅;
    for (∀ s ∈ tekući_skup_stanja)
       novi_skup_stanja:=novi_skup_stanja ∪ δ(s,tekući_ulaz);
    end for;
    tekući_skup_stanja := ε-closure(novi_skup_stanja);
    tekući_ulaz := novi simbol ulazne sekvence;
end while;
if (tekući_skup_stanja ∩ P ≠ ∅)
    then ulazna sekvenca se prihvata;
    else ulazna sekvenca se ne prihvata;
end if.
```


Rad datog NKA za ulaz abb

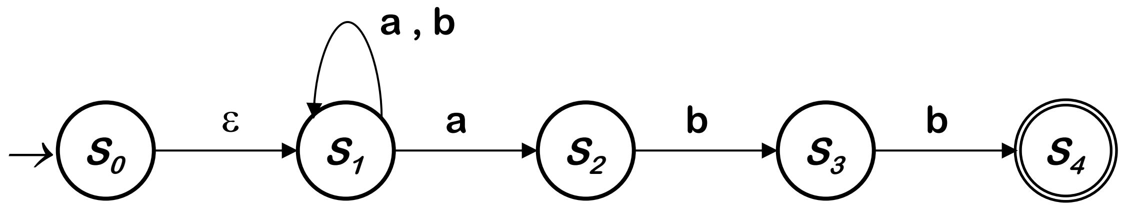

$s_0\ s_1 \xrightarrow{a} s_1\ s_2 \xrightarrow{b} s_1\ s_3 \xrightarrow{b} s_1\ s_4$ ***prihvata zbog s4***

ε-closure(s_0)

Odnos NKA i DKA

DKA je specijalan slučaj NKA

- DKA ima tačno jedno startno stanje
- DKA nema ε prelaza
- Funkcija prelaza DKA ima jedinstvenu vrednost
- Uvek se može konstruisati DKA koji je ekvivalentan (prepoznaje isti jezik) kao zadati NKA:
  - Svako stanje DKA je skup mogućih stanja NKA do kojih NKA može doći u toku rada
- Moguće eksponencijalno povećanje broja stanja

Konverzija NKA u DKA

NKA $\rightarrow$DKA

Algoritam koristi istu ideju kao algoritam rada NKA, samo što ne posmatra jednu ulaznu sekvencu, nego sistematski određuje tabelu prelaza DKA.

Algoritam:

1. Neka je s_0 startno stanje NKA.
2. Odrediti $S_0 = \varepsilon$-closure(s_0) koje postaje startno stanje DKA
3. novo_stanje_DKA = {}
4. Za svako s iz $S_{0,}$
5. Za svako α iz ulazne azbuke:

   novo_stanje_DKA = *novo_stanje_DKA* $\cup$ ε-closure (δ(s, α))
6. Označiti *novo_stanje_DKA* kao stanje prihvatanja, ako u svom skupu sadrži bar jedno stanje prihvatanja NKA
7. Iterativno ponavljati tačke 3-6 za sva dobijena stanja, dok postoji promena u skupu stanja DKA.

NKA →DKA prethodni primer

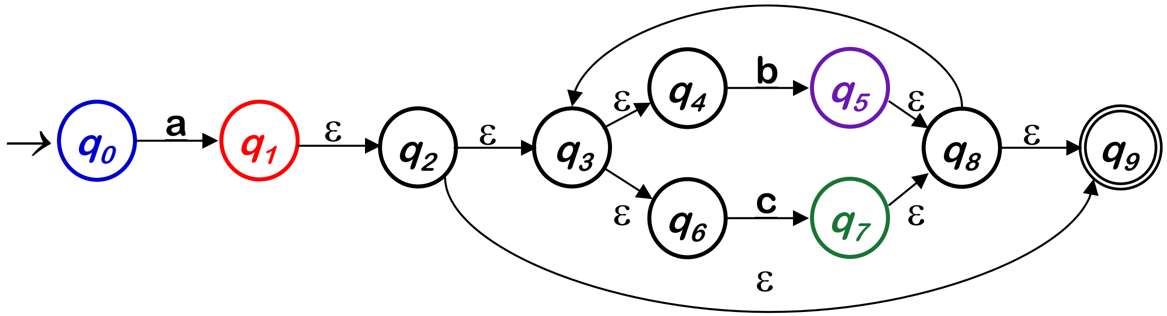

Određivanje ekvivalentnog DKA

ε-zatvaranje q1

	stanja DKA	stanja NKA	a	b	c	
→	s_0	q_0	$q_1, q_2, q_3, q_4, q_6, q_9$			0
	s_1	$q_1, q_2, q_3, q_4, q_6, q_9$		$q_5, q_8, q_9, q_3, q_4, q_6$	$q_7, q_8, q_9, q_3, q_4, q_6$	1
	s_2	$q_5, q_8, q_9, q_3, q_4, q_6$		s_2	s_3	1
	s_3	$q_7, q_8, q_9, q_3, q_4, q_6$		s_2	s_3	1

Samo tamo gde se u skupu stanja NKA nalazi završno stanje q9

NKA →DKA prethodni primer (2)

Rezultujući DKA

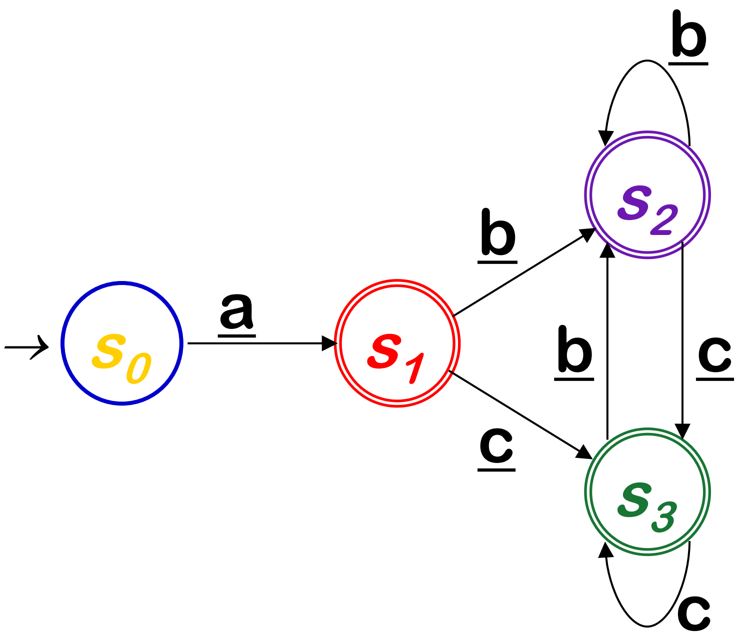

		a	b	c	
→	s_0	s_1	-	-	0
	s_1	-	s_2	s_3	1
	s_2	-	s_2	s_3	1
	s_3	-	s_2	s_3	1

Stanja s1, s2, s3 se ponašaju isto pa se mogu objediniti (tzv. minimizacija automata, biće obrađena na vežbama)

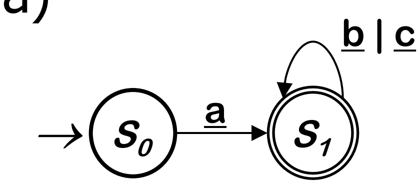

Regularni izrazi

Regularni izrazi

- Alternativni formalizam za opis jezika
- Regularni izrazi opisuju tačno isti skup jezika kao konačni automati:
  - Za svaki regularni izraz može se naći konačni automat koji opisuje isti jezik kao taj izraz
  - Za svaki konačni automat može se naći regularni izraz koji opisuje isti jezik kao taj automat

Definicija regularnog izraza

- Regularni izraz *s* opisuje regularni skup nizova znakova L(*s*).
- Regularni izrazi definišu se na sledeći način:
  - $\varnothing$ je regularan izraz koji opisuje prazan skup L($\varnothing$)=$\varnothing$.
  - ε je regularan izraz koji opisuje skup {ε} L(ε)={ε}. (sekvenca dužine nula znakova, tzv. *prazna* sekvenca)
  - niz znakova *n* je regularni izraz koji opisuje skup {*n*} L(*n*)={*n*}.

Definicija regularnog izraza (2)

- složeniji regularni izrazi dobijaju se od regularnih izraza A i B primenom operacija:
  - Opcije A?, $L(A?) = L(A) \cup \{\varepsilon\}$
  - unije A|B, $L(A|B) = L(A) \cup L(B) = \{x \mid x \in A \text{ ili } x \in B\}$
  - konkatenacije (nadovezivanja) AB ili A·B
    $L(AB)=L(A) \times L(B)=\{xy \mid x \in A, y \in B\}$
    Konvencija:
    $$A^n \equiv \underbrace{A \cdot A \cdot \ldots \cdot A}_{n} \qquad A^0 \equiv \{\varepsilon\}$$
  - zvezdastog zatvaranja A^*
    $A^*=A^0|A^1|A^2|A^3|\ldots$ (beskonačan broj članova)
  - pozitivnog zatvaranja A^+
    $A^+ = A^1|A^2|A^3|\ldots$

Primeri regularnih izraza

- $L(abc)=\{abc\}$ $L(a \mid b \mid c)=\{a, b, c\}$
- $L[(a \mid b)(c \mid d)]=\{ac, ad, bc, bd\}$ male zagrade su obavezne zbog prioriteta
- $L(a^*)=\{\varepsilon, a, aa, aaa, \ldots\}$
- $L[(a \mid b)^+]=\{a, b\} \cup \{a, b\} \times \{a, b\} \cup \{a, b\} \times \{a, b\} \times \{a, b\} \cup \ldots=\{a,b\} \cup \{aa, ab, ba, bb\} \cup \{aaa, aab, aba, abb, baa, bab, bba, bbb\} \cup\ldots= \{a, b, aa, ab, ba, bb, \ldots\}$ = svi mogući nizove slova a i b dužine 1 ili više
- Slovo =A | B |…| Z | a | b |…| z
  Cifra = 0 | 1 |…|9
  Identifikator = Slovo (Slovo | Cifra)*

Konstrukcija konačnog automata iz regularnog izraza

Tompsonov algoritam

- Za zadati reg. izraz određuje nedeterministički konačni automat

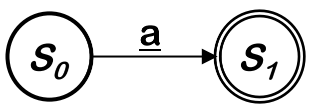

NKA for
a

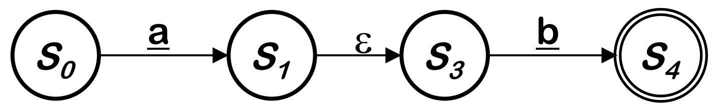

NKA for ab

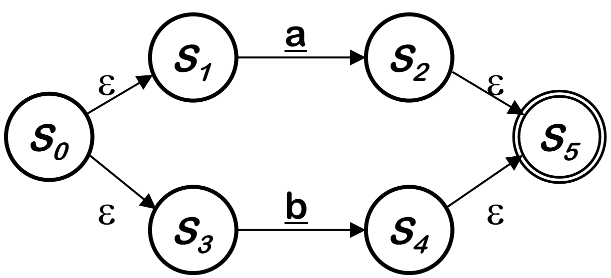

NKA for a | b

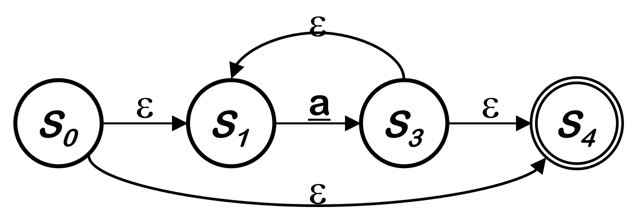

NKA for a^*

Ken Thompson, CACM, 1968

Primer primene Tompsonovog algoritma

Zadati reg. Izraz: a (b | c)*, krećemo od osnovnih komponenata pa kombinujemo u veće podizraze:

1. a, b, & c

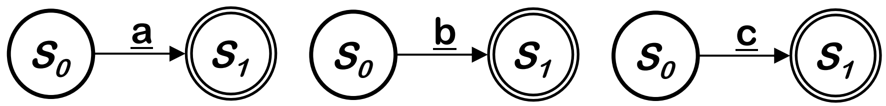

2. b | c

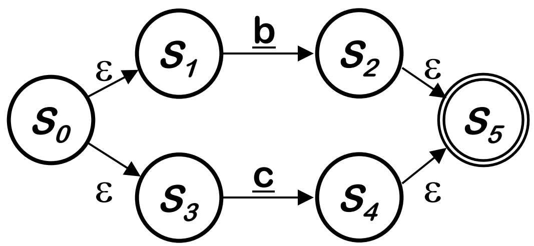

3. (b | c)*

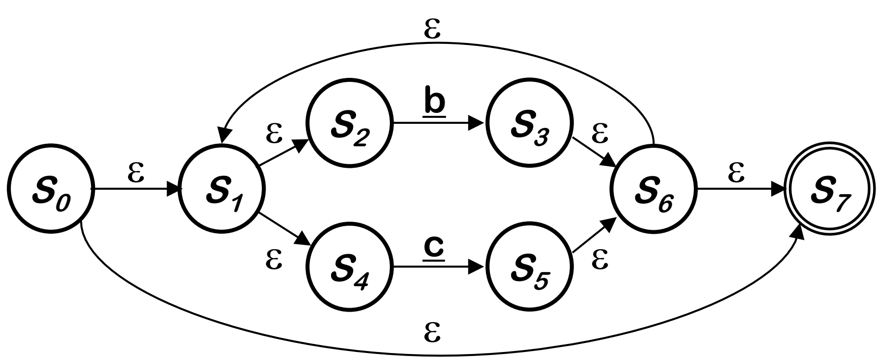

Primer primene Tompsonovog algoritma 2

4. $\underline{a}\ (\ \underline{b}\ |\ \underline{c}\ )^*$

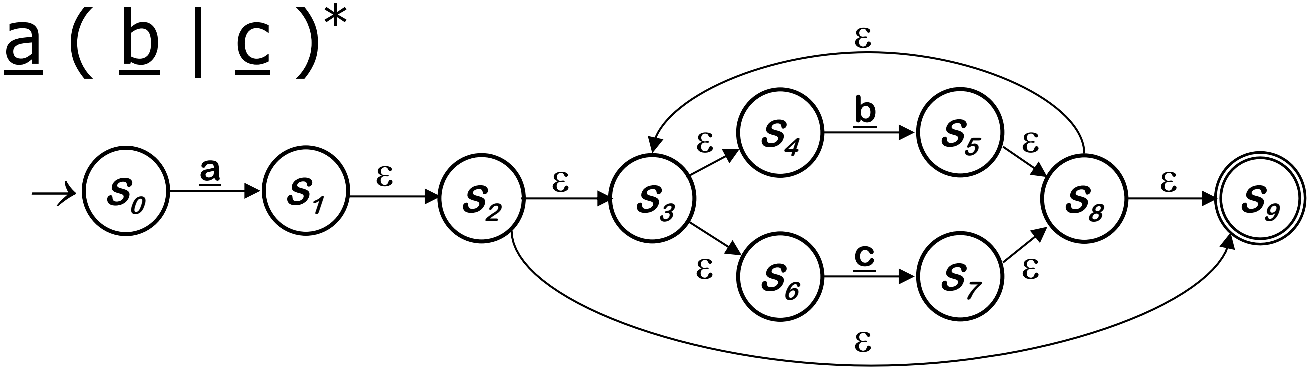

Posle konverzije u DKA i minimizacije broja stanja:

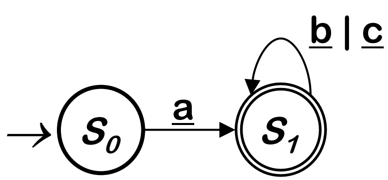

Automatizacija konstrukcije skenera

Formalna metodologija dobijanja programskog koda na osnovu specifikacije jezika:

1. Napisati RE za zadati ulazni jezik
2. Konstruisati NKA za dati RE Tompsonovim alg.
3. Konstruisati DKA ekvivalentan dobijenom NKA
4. (Po potrebi) odrediti minimalan DKA
5. Implementirati DKA iz tačke 4. programom

Generatori skenera rade po opisanom principu:

- Lex, Flex, jlex, jflex,...